EXAMEN
DATA PREPROCESSING

Département : IA & DATA
Année Académique : 2025-2026
Filière et niveau : INTELLIGENCE ARTIFICIELLE M1
Semestre : **1**
Durée : 3 jours
Travail : Individuel obligatoire

Consignes générales :

- Chaque étudiant doit choisir **un seul dataset**
- **Maximum 2 étudiants par dataset**
- Le travail est **strictement individuel**
- Toute ressemblance significative sera sanctionnée

Modalité de durée

Le décompte commence à partir du jour de réception du sujet

Chaque étudiant dispose de **3 jours exactement** pour soumettre son travail.

Livrables obligatoires

Chaque étudiant doit soumettre **3 éléments** :

1. Code Python

- Format : **Jupyter Notebook (. ipynb)** ou script .py
- Doit être :
  - Clair et structuré
  - Commenté
  - Exécutable sans erreur

Le code doit permettre de :

- Charger les données
- Effectuer tout le pré-processing
- Générer le dataset final

2. Rapport écrit

- Format : **PDF**
- Contenu :
  - Explications détaillées
  - Justification des choix

- Interprétation des résultats
- Graphiques commentés

Le rapport est **fondamental dans l'évaluation**

3. Présentation enregistrée

- Format : **PowerPoint (.pptx) + enregistrement vidéo**
- Durée : **5 à 10 minutes**

Contenu attendu :

- Présentation du dataset
- Problématique
- Démarche de pré-processing
- Résultats obtenus
- Difficultés rencontrées

Présentation orale **claire et structurée obligatoire**

Objectif

Réaliser un **prétraitement complet, rigoureux et justifié** d'un dataset réel en vue d'une utilisation en Machine Learning.

TRAVAIL À EFFECTUER

PARTIE 1 : Compréhension des données

- Description du dataset
- Types de variables
- Identification de la cible
- Interprétation métier

PARTIE 2 : Analyse exploratoire (AED)

- Analyse univariée
- Analyse bivariée
- Visualisations pertinentes
- Détection anomalies

PARTIE 3 : Nettoyage des données

- Valeurs manquantes (avec justification)
- Valeurs aberrantes
- Doublons

PARTIE 4 : Encodage et transformation

- Encodage catégoriel
- Normalisation / standardisation
- Justification

PARTIE 5: Feature Engineering

- Création de variables
- Sélection de variables

PARTIE 6: Dataset final

- Dataset propre et prêt pour ML

PARTIE 7 : Analyse critique

- Difficultés
- Choix importants
- Améliorations possibles

Liste datasets :
https://docs.google.com/document/d/12Ucj95on2fwIkkNgGk21RaN3V5DiXiF7d11UAlKLKBE/edit?usp=sharing